

Моделирование импульсных нейронных сетей с обучающимися синапсами RRAM, вдохновленное строением мозга

G. Pedretti, S. Bianchi, V. Milo, A. Calderoni, N. Ramaswamy, and D. Ielmini

Dipartimento di Elettronica, Informazione e Bioingegneria (DEIB), Politecnico di Milano and IU.NET

Аннотация

Вычисления, вдохновленные строением мозга, в настоящее время все больше набирают популярность, как жизнеспособная технология для искусственного интеллекта, позволяющая заниматься распознаванием, обработкой языков и обучением без учителя онлайн. В настоящее время существует два фундаментальных ограничения, которые препятствуют развитию проектирования схем, вдохновленных строением мозга: (I) понимание обработки импульсов, управляемых событиями, в человеческом мозге (II) разработка предиктивных моделей для проектирования и оптимизации когнитивных цепей. В данной работе мы хотим представить комплексную модель для нейронных сетей, основанную на пластичности, зависящей от времени импульса (STDP) в синапсах с резистивной коммутационной памятью (RRAM). Оба подхода, модель Монте Карло и аналитическая модель представлены для описания экспериментальных данных, полученных с помощью современного нейроморфного оборудования. Модель может предсказывать эффективность обучения и время в зависимости от входного шума и размера паттерна, тем самым открывая путь для моделирования когнитивных схем схожих с мозгом.

I. Введение

Недавно было показано, что нейроморфные вычисления с RRAM или памятью с фазовым переходом (PCM) позволяют распознавать рукописные символы [1] и лица [2], тем самым обеспечивая основу для компьютерного зрения и навигации дронов/роботов/автомобилей. Все эти достижения обычно основаны на архитектурах глубокого обучения с учителем и алгоритмом обратного распространения ошибки, которые, однако, не имеют аналогии с человеческим мозгом и не подходят для обучения без учителя онлайн. С другой стороны, нейронные сети с импульсной зависимостью от времени (STDP) способны воспроизводить биореалистичное обучение без учителя онлайн [3,4]. Было показано, что нейроморфная схема на основе RRAM выполняет обучение и распознавание статических и динамических паттернов путем реализации правила обучения STDP на аппаратном уровне [5]. Изучение нескольких паттернов было продемонстрировано в экспериментах [5] и при моделировании [6] через обновления весов при помощи STDP. Однако возможности разрабатывать

и оптимизировать схемы, вдохновленные строением мозга, препятствует недостаточная точность предиктивных моделей.

Мы представляем новые модели обучающих схем, основанных на STDP. После описания эталонного оборудования для обучения STDP с синапсами RRAM, мы представим, как модели Монте-Карло (MC), так и аналитические модели, которые могут предиктивно описывать эволюцию весов во времени и влияние параметров схемы (порог интегрирования) и входных параметров (шум) на структуру, эффективность и время обучения. Наконец, мы раскроем весь потенциал моделей для решения оптимизированной проблемы обучения и распознавания наборов данных MNIST.

II. Нейроморфное аппаратное обеспечение

Мы изучали нейронные сети прямого распространения с обучением без учителя через STDP в синапсе с одним транзистором и одним резистором (1T1R) Рис. 1a, состоящим из устройства RRAM с выбранным транзистором [7]. Синаптические ворота подключены к пресинаптическому нейрону (PRE), а верхний электрод (TE) и нижний электрод (BE) подключены к постсинаптическому нейрону (POST). Импульс PRE вызывает импульс тока через синапс 1T1R, достигающий POST через BE. Попадание импульсов тока в POST повышает внутренний потенциал, в конечном итоге вызывая срабатывание. При срабатывании к ТЕ применяется импульс обратной связи, который может привести к установке/сбросу RRAM, если он перекрывается с выбросом PRE. Задержка положительного импульса, когда импульс в POST возникает в ответ на импульс в PRE, вызывает процесс установки или потенцирование. Задержка отрицательного импульса, когда импульс POST возникает в ответ на предыдущий импульс PRE, вызывает процесс установки или депрессию. Полносвязная структура перцептрона с прямым распространением (Рис. 1b) позволяет распознавать визуальные образы посредством стохастического обучения, при котором образец и шум альтернативно передаются 1-ым уровнем (PRE) на 2-ой уровень (POST) через синапсы STDP.

На Рис. 1c показано нейроморфное оборудование, реализованное с синапсами 1T1R и микроконтроллером Arduino (μC). Эта нейронная сеть была впервые использована для демонстрации полностью аппаратного обучения без учителя с синапсами RRAM [5].

В качестве синаптического элемента использовались устройства RRAM на основе HfO_x с током установки/сброса $< 50 \mu A$ Рис. 2а и средним окном сопротивления около $10x$ Рис. 2б. В этой нейроморфной схеме синаптические веса могут отслеживаться в режиме онлайн, как показано на Рис.3: по мере того, как входные импульсы паттерна и шума передаются в нейронную сеть, синапсы в паттерне (диагональ '//' на рисунке) потенцируются, в то время как синапсы на заднем плане (вне рисунка) вдавлены. Мониторинг синаптических весов позволяет напрямую оценить эффективность обучения, энергию и время. Это современное оборудование, созданное на основе структуры мозга, с синаптической сетью $4x4$ было использовано для сбора экспериментальных данных при обучении без учителя с помощью STDP.

А. Модель Монте-Карло

Модель МС была разработана для описания процессов установки/сброса, происходящих в каждую эпоху (то есть, событие представления шаблона/шума) в процессе обучения. Реакция RRAM на перекрывающиеся импульсы PRE/POST моделировалась аналитической моделью нитевидного переключения (см. Моделирование на Рис. 2а) [8]. Стохастическая изменчивость установки/сброса была смоделирована путем предположения логарифмически нормального распределения сопротивления HRS и LRS, R при увеличении напряжения, как показано на Рис. 2б. На Рис. 3б показаны рассчитанные веса во время стохастической подачи импульсов входного шаблона, подчеркивая точное предсказание потенциации и депрессии с реалистичными вариациями синаптических весов $\frac{1}{R}$.

В. Аналитическая компактная модель

Для прогнозирования среднего обучающего поведения сети с помощью модели МС требуются длительные симуляции для усреднения эффектов изменчивости. Чтобы ускорить оценку обучения STDP, мы разработали высокоуровневую аналитическую компактную модель, принимающую уравнения скорости для синаптического веса в паттерне [G_P в Ур. (1), Рис. 4а] и на заднем плане [G_B в Ур. (2), Рис. 4а]. Уравнения скорости включают все возможные последовательности входных импульсов (например, шаблон/шум, шум/шаблон и т.д.) в качестве движущей силы для потенциации/депрессии (Табл. I). Например, последовательность паттерн/шум вызывает потенцирование паттерна в Ур. (1) и депрессия фона в Ур. (2). И наоборот, последовательность шум/шаблон вызывает депрессию шаблона и усиление фона, в то время как шум/шум вызывает рандомизацию весов, а шаблон/шаблон предотвращается рефрактерным временем, когда любой PRE остается неактивным в течение одного периода после импульса. Аналитическая компактная модель может предсказать временную эволюцию G_P и G_B для любого набора входных переменных на Рис. 4б в соответствии с параметрами

Ур. на Рис. 4с.

III. РЕЗУЛЬТАТЫ МОДЕЛИРОВАНИЯ

Мы провалидировали предиктивные модели обширным изменением параметров стохастического обучения. Рис. 5 иллюстрирует подход стохастического обучения в сетях STDP, где периоды паттернов и шума случайным образом чередуются (Рис. 5а). В эпоху паттерна, паттерн представляется с плотностью P , заданной числом пикселей узора, деленным на общий размер изображения. В эпоху шума импульсы шума случайным образом активируются с вероятностью N , например, $1/10$ PRE активируется в каждую эпоху шума для $N = 10\%$ (Рис. 5б). Вероятность R_P представления шаблона и R_N представления шума составляет 50% , если не указано иное. Был принят порог интегрального тока $Q = 0,5 \mu C$ на синапс паттерна. Во время процесса обучения, который обычно длится 1000 эпох (10 с), отслеживались синаптические веса и изучалась эффективность обучения для различных значений P , N , R_P и R_N .

С. Влияние плотности шума N .

Поскольку шум ускоряет фоновую депрессию, которая является самым медленным процессом в динамике обучения (например, см. Рис. 3), мы изучили влияние N на эффективность и скорость обучения. На Рис. 6 показаны представленные входные данные (вверху), измеренные синаптические веса (в центре) и расчеты МС (внизу) для увеличения плотности шума $N = 5\%$ (а), 10% (б) и 15% (с). По мере увеличения N депрессия ускоряется, как и ожидалось, однако обучение также становится менее стабильным, о чем свидетельствуют колебания веса со временем. Нестабильное обучение при большом N происходит из-за шумовых импульсов, вызывающих срабатывание: если за срабатыванием следует представление паттернов, все синапсы паттернов подвергаются депрессии и имеет место усиление фона, как показано на Рис. 6 скорость обучения и нестабильность при увеличении N . Рис. 7а суммирует эффективность обучения, показывая вероятность истинного срабатывания P_{learn} (срабатывание в ответ на представление шаблона) и вероятность ложного срабатывания P_{err} (срабатывание в ответ на неправильный паттерн), показывая, что P_{learn} уменьшается, а P_{err} увеличивается при увеличении N в результате нестабильного обучения. Расчеты МС хорошо согласуются с данными, что демонстрирует предсказуемость обучения STDP. На Рис. 7б показаны измеренные и вычисленные веса $1/R$ после 1000 эпох как функция от N , снова показывая закрытие окна из-за нестабильного обучения при большом N . На Рис. 7с показано время обучения t_{learn} , а именно время для среднего веса фоновые синапсы падают ниже 1.510^{-5-1} (см. вставку). Лучший компромисс между скоростью обучения (Рис. 7с) и стабильностью (Рис. 7а и б) для $N = 3\%$.

Д. Влияние плотности паттерна P .

Представление паттернов приводит к вспышке, поэтому потенцирование паттернов синапсов наиболее эффективно, если плотность паттернов P намного больше, чем N . Для изучения влияния плотности паттернов P на обучение на Рис. 8а показаны измеренные и вычисленные P_{learn} и P_{err} как функции P , для $N = 3\%$. P_{learn} увеличивается, а P_{err} уменьшается для $P > 20\%$, таким образом, намного больше, чем N . Для P , сравнимого с N , шум и паттерн конкурируют в потенцировании, таким образом препятствуя обучению. На Рис. 8b показаны измеренные и вычисленные веса как функция от P , что указывает на закрытие окна для уменьшения P . Время обучения на Рис. 8с показывает аналогичное улучшение скорости для увеличения P благодаря усилению потенцирования модели.

Е. Влияние вероятности паттерна/шума.

Варьируется вероятность R_P шаблона и вероятность шума R_N , при $R_P + R_N = 100\%$, что влияет на эффективность и скорость обучения, как показано на Рис. 9. Увеличение R_P приводит к потенцированию шаблона и, следовательно, к увеличению P_{learn} и уменьшению P_{err} . По той же причине окно между весами узора и фона увеличивается на Рис. 9b. Эти результаты показывают, что оптимальная вероятность $R_P = R_N = 50\%$, что может быть достигнуто путем систематического (а не случайного, как на Рис. 5) чередования между входными каналами шаблона и шума.

IV. ОПТИМИЗИРОВАННОЕ РАСПОЗНАВАНИЕ ЦИФР

На Рис. 10 показан контурный график обучения t_{learn} , как функции P и N в соответствии с аналитической моделью. Во время обучения минимизируется $N \ll P$, где шаблон усиливается, а фон эффективно подавляется. На рисунке выделены точки максимального окна, соответствующие оптимизированному значению N для любого заданного значения P . Это позволяет оптимизировать процесс стохастического обучения в отношении времени обучения и эффективности.

Чтобы проверить влияние оптимизированных параметров на обучение, мы смоделировали обучение без учителя и классификацию рукописных цифр из базы данных MNIST. На Рис. 11 показана принятая схема, состоящая из трехслойного перцептрона с 28×28 PRE в 1-м слое, 50 000 POST во 2-м слое и 10 классификационных нейронов в 3-м слое. [9]. Синапсы между 1-м и 2-м уровнями обучаются (STDP) обучением без учителя, а синапсы между 2-м и 3-м уровнями обучаются обучением с учителем для классификации. Обучение без учителя проводилось либо с фиксированным N ($N = 5\%$ и $N = 10\%$), либо с оптимизированным N (Рис. 10). На Рис. 12 показана эффективность обучения, а именно сопоставление синаптических весов с шаблоном после обучения, и эффективность классификации, а именно вероятность истинного срабатывания

и ложного срабатывания на уровне классификации. В целом оптимизированный N дает наилучшую эффективность около 92% (обучение) и 85% (классификация). Рис. 13 суммирует вероятности истинного срабатывания/ложного срабатывания для оптимизированного N , поддерживая надежное распознавание основанное на моделировании.

V. ВЫВОДЫ

Мы представляем новую методологию разработки и оптимизации импульсной нейронной сети для обучения без учителя, вдохновленного строением мозга, с использованием STDP в синапсах RRAM. Мы показываем, что модели МК цепей RRAM и аналитические компактные модели динамики STDP точно предсказывают поведение обучения в современной импульсной сети с синапсами RRAM. Наконец, мы демонстрируем повышение эффективности обучения до 92% за счет использования оптимизированного шума во время обучения без учителя рукописным цифрам из базы данных MNIST, тем самым открывая путь для предиктивного проектирования и контроля обучающих схем STDP.

БЛАГОДАРНОСТИ

Эта работа была частично поддержана Европейским исследовательским советом. (грант ERC-2014-CoG-648635-RESCUE).

References

- [1] G. W. Burr, et al., IEEE Trans. Electron Devices 62, 3498 (2015).
- [2] P. Yao, et al., Nat. Commun. 8, 15199 (2017).
- [3] P. A. Merolla, et al., Science 345, 668–673 (2014).
- [4] N. Qiao, et al., Front. Neurosci. 9:141. (2015).
- [5] G. Pedretti, et al., Sci. Rep. 7:5288 (2017).
- [6] P. U. Diehl and M. Cook, Front. Comput. Neurosci. 9, 99 (2015).
- [7] S. Ambrogio, et al., IEEE Trans. Electron Devices 63, 1508 (2016).
- [8] S. Ambrogio, et al., IEEE Trans. Electron Devices 61, 2378 (2014).
- [9] S. Ambrogio, et al., Symp. VLSI Tech. Dig., 196 (2016).